UNIVERSIDAD CATÓLICA BOLIVIANA

“SAN PABLO”

Propuesta del Proyecto: Proyecto Integrador

Integrantes:

- Lopez Castillo Kael Alessandro
- Medina Paredes Esmeralda Paula
- Parra Aguilar Franco Jhoel
- Rodas Miranda Camila Nicole
- Torrez Calle Álvaro Ariel

Docente: Ovidio Roger Paton Gutierrez

Fecha: 17 / 04 / 2026

Materia: Machine Learning

Equipo: Vincit Data

1. Fundamentación, Contexto y Definición del Problema

En la era de la economía de la atención, las plataformas de contenido digital se enfrentan al fenómeno de la "sobrecarga de información". Con catálogos que superan los 60,000 títulos, la capacidad del usuario para descubrir contenido relevante de forma manual es nula. El problema central de este proyecto es el diseño y validación de un **Motor de Recomendaciones Híbrido** capaz de personalizar la experiencia de navegación para más de 160,000 usuarios activos.

El desafío técnico se desglosa en dos frentes críticos:

1. **Sparsity (Dispersión):** La matriz de interacciones usuario-ítem presenta una densidad de apenas el **0.26%** (Sparsity del 99.74%), lo que invalida los enfoques de cálculo denso tradicional y obliga a la implementación de modelos de factores latentes.
2. **Problema del Cold-Start:** El sistema debe ser capaz de recomendar películas nuevas que aún no poseen calificaciones históricas. Para resolver esto, el enfoque híbrido propuesto utilizará metadatos semánticos (géneros y tags) para servir de puente cuando el filtrado colaborativo falle.

2. Fuente de Datos Verificada y Arquitectura de Información

Se utilizará el dataset **MovieLens 25M**, un estándar de oro en la industria de sistemas de recomendación, distribuido por GroupLens Research. El proyecto se estructurará sobre la integración de cuatro archivos principales, cuya integridad será verificada mediante hashes de lectura:

- **`ratings.csv`:** Contiene 25,000,095 calificaciones en una escala de 0.5 a 5.0. Este archivo es el núcleo para el entrenamiento de los modelos de filtrado colaborativo (SVD, NMF y NCF).
- **`movies.csv`:** Almacena los metadatos de 62,423 películas, incluyendo títulos y géneros. Será la base para el filtrado basado en contenido y la posterior búsqueda semántica.
- **`genome-scores.csv`:** Representa el "ADN de la película" mediante 15.5 millones de coeficientes de relevancia entre películas y etiquetas genómicas.

Estos datos permitirán la creación de vectores de características de alta dimensionalidad.

- **`genome-tags.csv`:** Catálogo de 1,128 etiquetas descriptivas que permiten interpretar los resultados de los modelos de agrupamiento y recuperación.

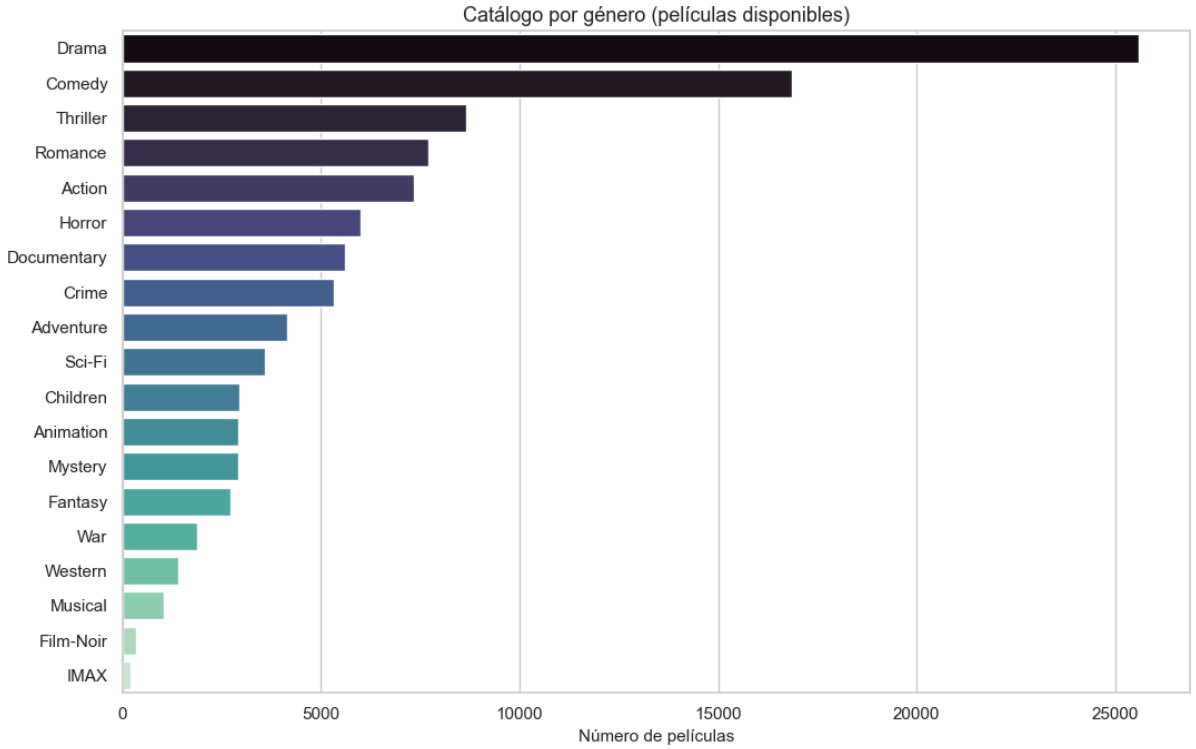

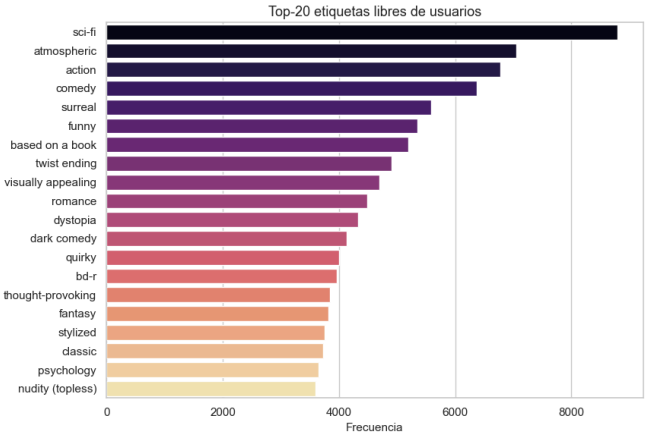

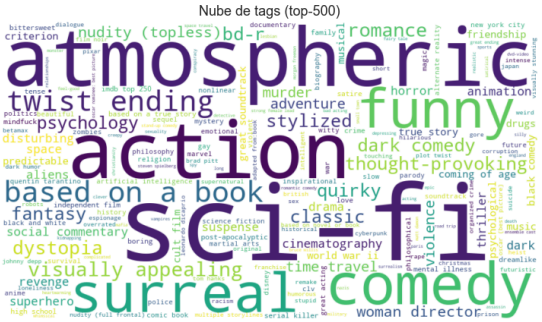

3. Descripción Preliminar de los Tres Mini Proyectos

El proyecto se desarrolla bajo una arquitectura progresiva donde cada fase alimenta a la siguiente:

3.1 Fase de Machine Learning Clásico

El objetivo es establecer una línea base (*baseline*) robusta. Se implementará un sistema de **Popularidad Bayesiana Ponderada** que penalice películas con pocos votos para evitar sesgos de varianza extrema. Posteriormente, se compararán tres modelos manuales: **KNN-Baseline** (basado en ítems), **SVD** (factorización matricial) y **NMF**.

Uso de AutoML: Se utilizará **PyCaret** para ejecutar una búsqueda automatizada de hiper parámetros sobre un subconjunto del 20% de los datos. Este proceso servirá como benchmark obligatorio para validar si el diseño manual del equipo es competitivo frente a optimizaciones automáticas.

3.2 Fase de Deep Learning (Modelado Avanzado)

Se superará la linealidad del SVD mediante una red neuronal de **Filtrado Colaborativo Neuronal (NCF)** implementada en **PyTorch**. La arquitectura constará de dos "brazos" o torres de entrada que procesarán capas de nn.Embedding para usuarios y películas simultáneamente. El objetivo es aprender representaciones no lineales en el espacio latente, optimizando una función de pérdida de error cuadrático medio (MSE) para mejorar la precisión del ranking Top-N.

3.3 Fase de MLOps + RAG (Recuperación Semántica)

Se transformará el modelo en un sistema productivo. Los *embeddings* generados en la fase de Deep Learning se indexarán en una base de datos vectorial (**Faiss** o **ChromaDB**). Esto permitirá que el sistema realice búsquedas por similitud en milisegundos, habilitando un flujo de recuperación semántica sobre los *tags* de los usuarios. El componente de MLOps garantizará la trazabilidad mediante el uso de **MLflow** para el registro de experimentos y el versionado de artefactos con **DVC**.

La evaluación seguirá el protocolo estricto de **CRISP-DM**. Dado que el dataset presenta un sesgo positivo (82% de ratings >= 3.0), se han definido los siguientes criterios de éxito:

- **Métricas de Regresión:** El éxito se definirá mediante la minimización del **RMSE** (Root Mean Squared Error) y **MAE**, buscando superar el rendimiento del SVD clásico con la arquitectura neuronal.

- **Métricas de Ranking (Top-N):** Se evaluará la relevancia de las 10 recomendaciones principales mediante **Precision@10**, **Recall@10** y **NDCG@10**. Se considerará una película como "relevante" sólo si posee un rating real >= 4.0 estrellas para evitar la inflación artificial de métricas.
- **Criterio de Inferencia:** El sistema debe responder en menos de 200ms para ser considerado viable en un entorno de producción simulado.

4. Riesgos, Factibilidad y Consideraciones Éticas

4.1 Gestión de Recursos y Escalabilidad

El riesgo principal es el consumo de memoria RAM al procesar 25 millones de filas (aproximadamente 2.5 GB en crudo). Como estrategia de mitigación, se implementará el uso de **Polars** con ejecución *lazy* y **Dask** para procesamiento por lotes. En el desarrollo local, se trabajará con una muestra estratificada representativa del 5% de los usuarios, asegurando que la distribución de "Power Users" y "Casual Users" se mantenga idéntica a la población original.

4.2 Reflexión Ética y Sesgo Algorítmico

Como parte del enfoque transversal de la materia, el proyecto dedicará un capítulo al análisis del **Sesgo de Popularidad** y las **Burbujas de Filtro**. Se evaluará cómo el algoritmo tiende a recomendar películas que ya son populares, excluyendo contenido diverso del catálogo (*long tail*). Se propondrá una métrica de diversidad intra-lista para cuantificar qué tan variado es el conjunto de recomendaciones entregado al usuario, buscando un equilibrio entre precisión y descubrimiento de nuevo contenido.

- **Riesgo 1: Desbordamiento de Memoria (RAM).** Procesar 25M de interacciones provoca errores Out-Of-Memory (OOM).
    - *Mitigación:* Se utilizará procesamiento *lazy* mediante **Polars** y un muestreo estratificado representativo del 5% basado en los percentiles de actividad de los usuarios.
- **Riesgo 2: Ruido en Long Tail.** Un gran porcentaje del catálogo carece de votos suficientes, lo que degrada matemáticamente el filtrado colaborativo.

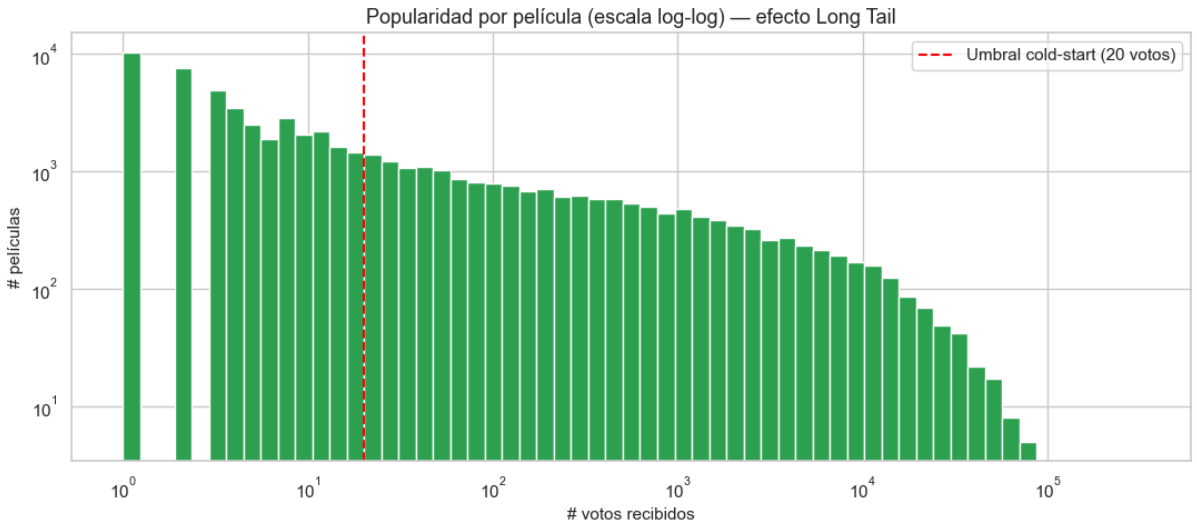

- *Mitigación:* Como se evidencia en la Figura 1, se aplicará un filtro de *cold-start*, descartando películas con menos de 20 votos.

5. Estructura del Proyecto

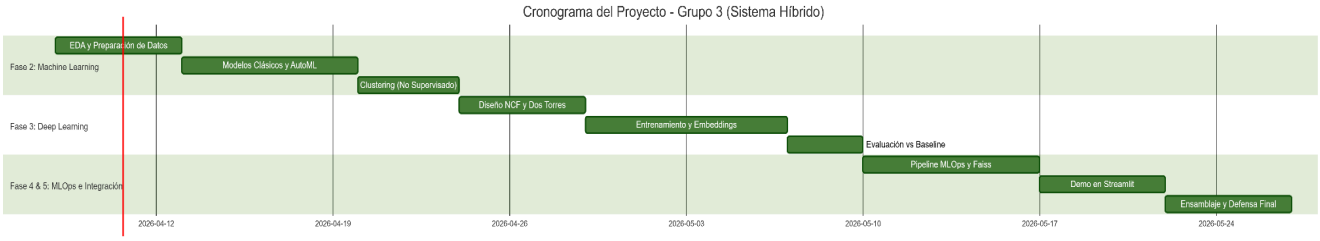

Fase 1 (Semana 1 - 7 días totales): Inicia con 3 días para definir el problema y justificar el sistema híbrido, seguidos de 4 días para el EDA masivo y el muestreo de datos.

Fase 2 (Semanas 2 y 3 - 14 días totales): Se dedican 8 días fuertes a limpiar datos y entrenar los modelos clásicos. Luego, 6 días para el clustering y correr el benchmark de AutoML.

Fase 3 (Semana 4 - 7 días totales): 4 días para levantar la arquitectura NCF en PyTorch y 3 días para sacar los embeddings y compararlos.

Fase 4 (Semana 5 - 7 días totales): 4 días configurando el tracking (MLflow) y la base vectorial, seguidos de 3 días programando la interfaz/API.

Fase 5 (Semana 6 - 7 días totales): 4 días para ensamblar los documentos y escribir la reflexión ética, dejando los últimos 3 días exclusivamente para ensayar la defensa.