UNIVERSIDAD CATÓLICA BOLIVIANA
“SAN PABLO”

Análisis Exploratorio y Modelado Clásico: Sistema de recomendación de películas

Integrantes:

- Lopez Castillo Kael Alessandro
- Medina Paredes Esmeralda Paula
- Parra Aguilar Franco Jhoel
- Rodas Miranda Camila Nicole
- Torrez Calle Álvaro Ariel

Docente: Ovidio Roger Paton Gutierrez

Fecha: 24 / 04 / 2026

Materia: Machine Learning

Equipo: Vincit Data

1. Resumen

Este informe documenta el diseño y validación de modelos clásicos de recomendación para el dataset MovieLens 25M bajo el estándar CRISP-DM. Mediante un submuestreo estratificado, se redujo el ruido de la *long tail*, permitiendo entrenar enfoques matriciales (SVD, NMF) y basados en vecindad (KNN), contrastarlos con un benchmark de AutoML. El modelo SVD demostró ser el más eficiente, mientras que el clustering con K-Means permitió identificar perfiles de audiencia basándose en representaciones latentes.

2. Análisis Exploratorio de Datos (Data Understanding)

El análisis bivariado y univariado se ejecutó sobre la totalidad poblacional (25 millones de registros) utilizando Polars (*lazy evaluation*) para evitar desbordamientos de RAM. Los hallazgos estructurales son:

- **Sesgo Positivo en Variable Objetivo:** El 82.11% de las calificaciones son \ge 3.0 estrellas. Las predicciones deben enfocarse en el umbral superior (rating 4.0 y 5.0) para evaluar recomendaciones verdaderamente relevantes.

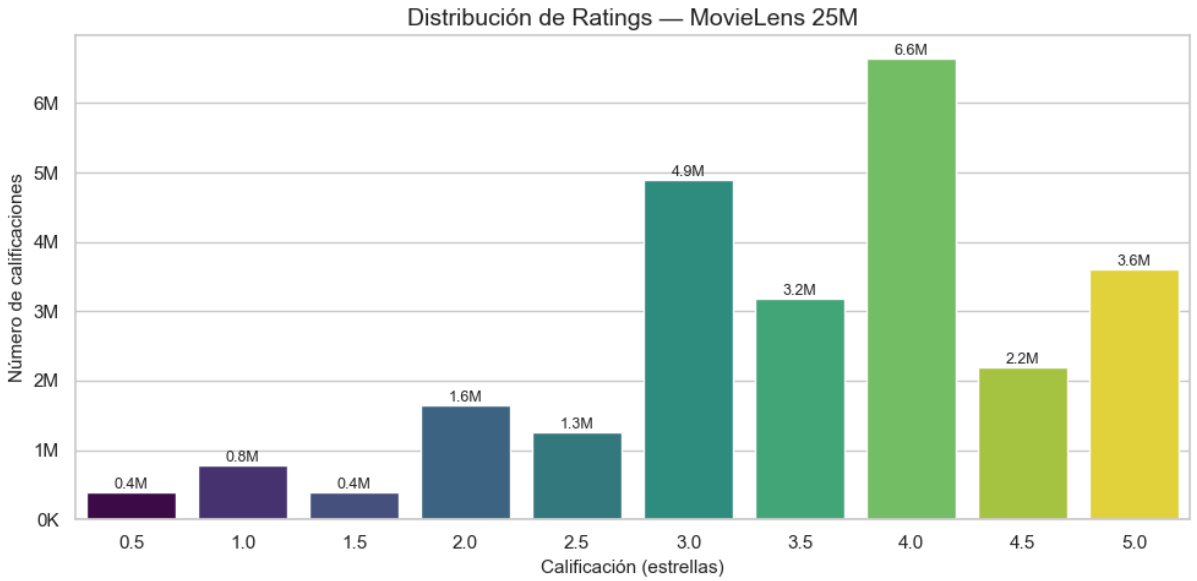

- **Ley de Potencias (Power Users):** El 36.93% de los usuarios concentra el 80% del total de las calificaciones. Realizar un muestreo aleatorio simple destruiría la estructura subyacente de la red de usuarios.

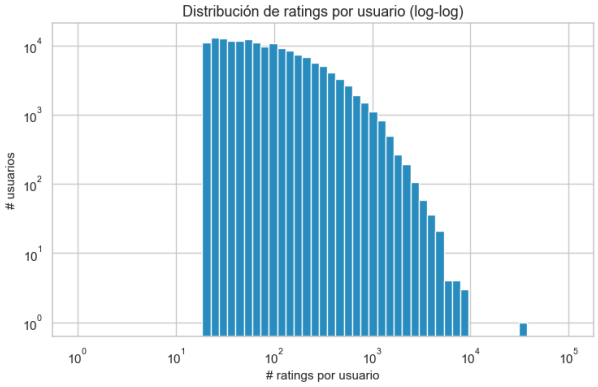

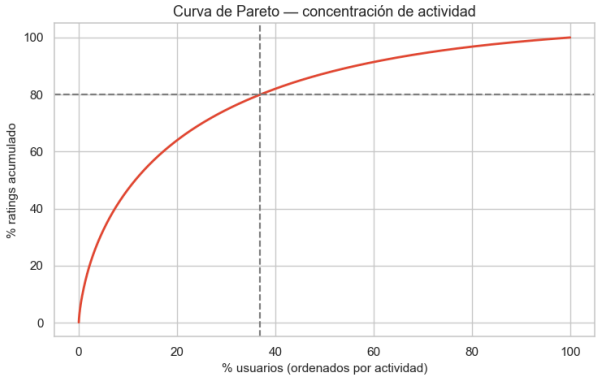

- **Relación Popularidad vs Calidad:**

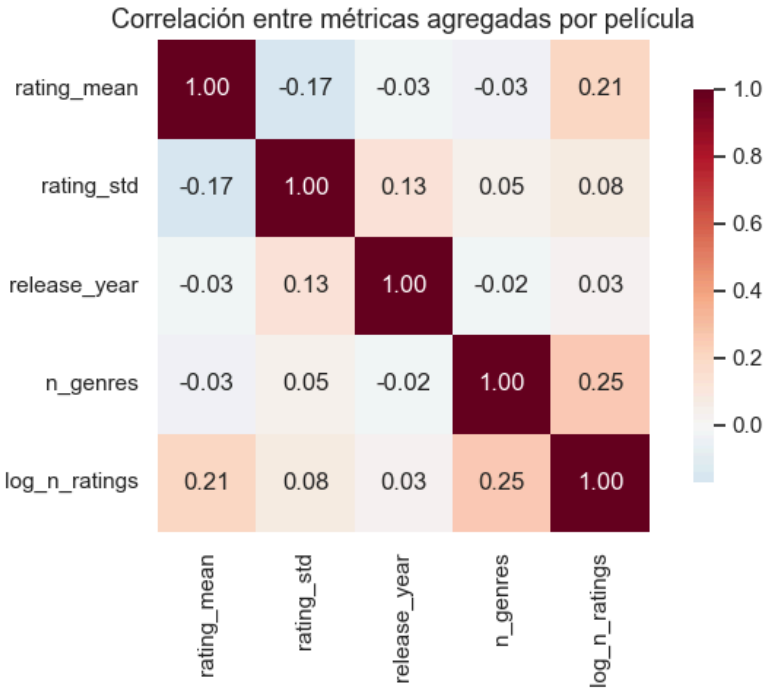

- **Sparsity Extrema:** La matriz usuario \times película contiene una densidad de apenas el 0.26% (Sparsity: 99.74%). Este factor imposibilita el uso de algoritmos densos y justifica la elección de Factorización Matricial (SVD/NMF) para el modelado.

3. Preparación de Datos (Data Preparation)

Para hacer factible el modelado local se diseñó un pipeline estricto:

1. **Muestreo Estratificado (5%):** Se dividió a los usuarios en tres *tiers* (Casual, Regular, PowerUser) según su volumen histórico mediante cuantiles (pd.qcut). Se extrajo aleatoriamente (SEED=42) el 5% de cada estrato.

2. **Filtro Cold-Start:** Se descartaron películas con menos de 20 interacciones dentro de la muestra, eliminando la volatilidad de la *long tail*.

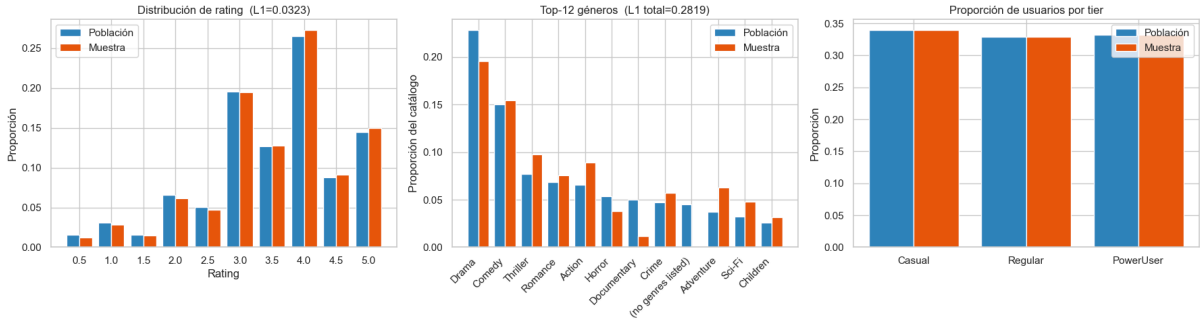

La muestra consolidada consta de 1,152,574 ratings y fue almacenada en formato columnar Parquet para garantizar reproducibilidad.

4. Modelado (Modeling)

El conjunto de datos se particionó al 80/20. Todos los modelos fueron sometidos a la misma partición y evaluados bajo métricas de regresión (RMSE, MAE) y métricas de *ranking* (P@10, R@10, NDCG@10).

1. **Baseline (Popularidad Bayesiana Ponderada):** Se utilizó *shrinkage* hacia la media global para estabilizar películas con pocos votos:

$$WR = \frac{v}{v+m} \cdot R + \frac{m}{v+m} \cdot C$$

2. **Modelos Clásicos:**
   - **KNN-Baseline (Item-Based):** k=40, similitud de Pearson corregida.
   - **SVD (Factorización Matricial):** n_factors=50, epochs=20. Descompone la matriz sparse en factores latentes.
   - **NMF:** n_factors=15, forzando representaciones aditivas (no-negativas) para priorizar interpretabilidad temática.

4.1 Benchmark Obligatorio con AutoML

Se ejecutó un GridSearchCV como flujo AutoML sobre el 20% de la muestra, iterando sobre los hiperparámetros de SVD, NMF, KNN y BaselineOnly. El AutoML

seleccionó un modelo base optimizado por SGD (n_epochs=20) con un RMSE en validación de 0.8871. Este modelo "ganador" fue reentrenado en todo el *trainset* para la comparación final.

5. Evaluación y Análisis de Error (Evaluation)

Modelo	RMSE	MAE	P@5	R@5	P@10	R@10	NDCG@10	Tiempo (s)
KNN-Baseline (item-based)	0.7986	0.6015	0.6928	0.3005	0.6822	0.3759	0.8464	27.2175
SVD	0.8140	0.6165	0.6583	0.2625	0.6491	0.3301	0.8351	3.0519
AutoML → BaselineOnly	0.8532	0.6501	0.5640	0.2330	0.5587	0.2950	0.8106	73.1075
NMF	0.8626	0.6571	0.5920	0.2469	0.5866	0.3099	0.8049	7.4900

Baseline (Pop. Bayesiana)	**0.9584**	**0.7415**	**0.6146**	**0.1946**	**0.6118**	**0.2152**	**0.8120**	**0.6998**

Análisis Crítico:

- SVD es el claro ganador en relación precisión/costo computacional. Logra un RMSE competitivo (0.8140) y el segundo mejor NDCG@10 (0.8351) en apenas 3.0 segundos.
- KNN-Baseline obtiene marginalmente mejores resultados de error (RMSE 0.7986), pero sufre de nula escalabilidad espacial y temporal (27.2s de entrenamiento), haciéndolo inviable para producción a gran escala.
- El flujo de AutoML demostró que los hiperparámetros estándar del SVD ya estaban cerca del óptimo global, confirmando su robustez.

6. Componente No Supervisado: Clustering de Embeddings

Utilizando los factores latentes (vectores de 50 dimensiones) generados por el algoritmo SVD, se aplicó segmentación con **K-Means**.

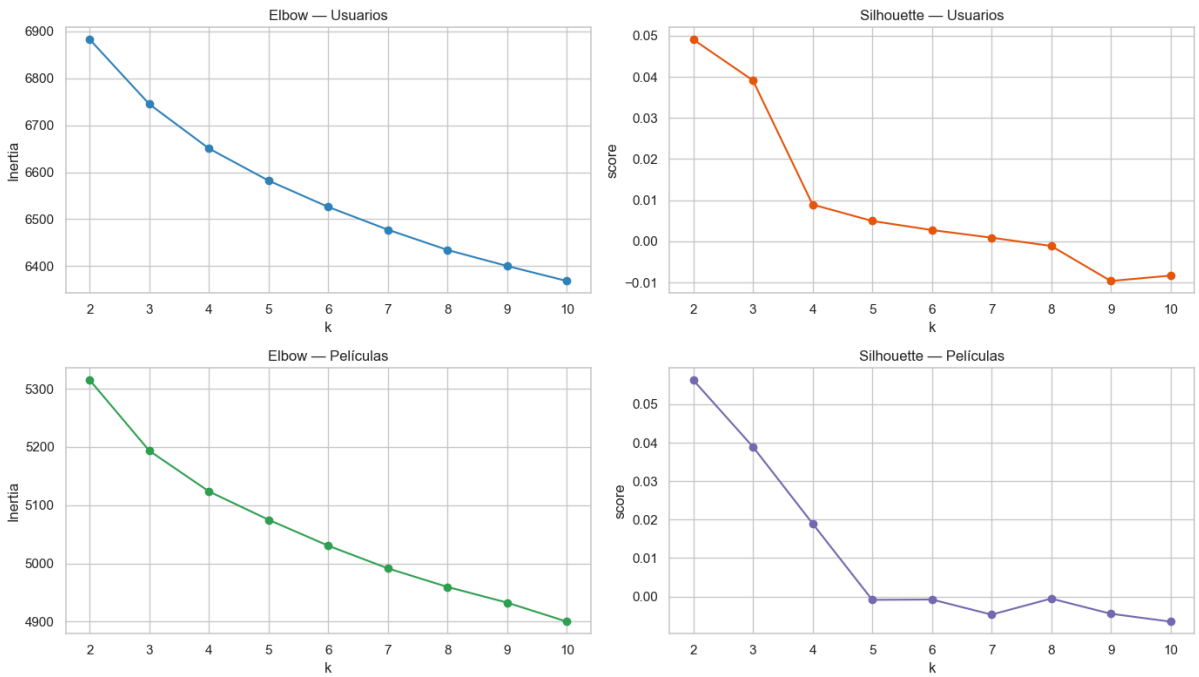

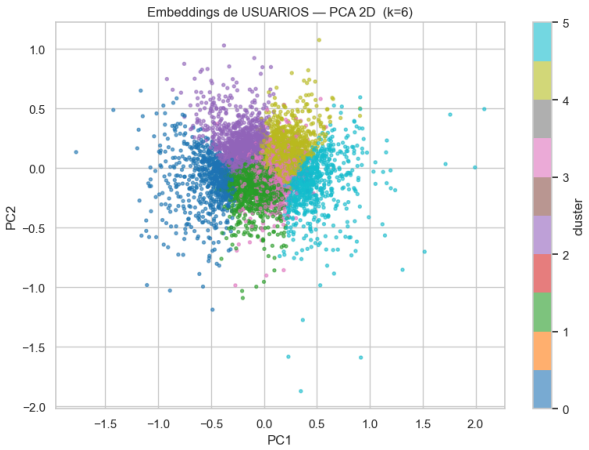

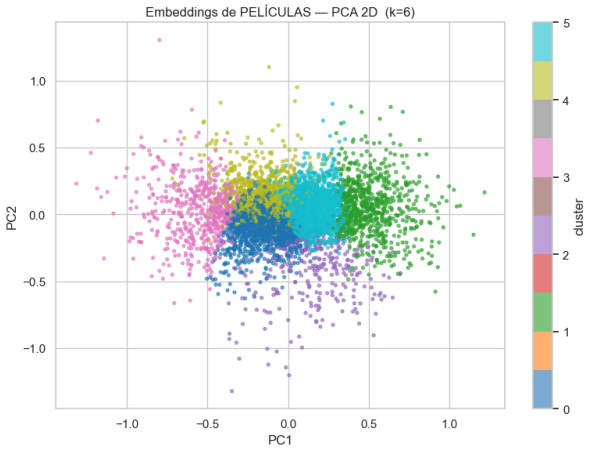

Interpretación de Resultados:

Al cruzar los 6 clústeres de ítems con los géneros de *movies.csv*, se revelaron perfiles de catálogo nítidos:

- **Clúster 2 (Blockbusters Históricos):** Ej. *Star Wars, Jurassic Park*. Altísima popularidad media (463 interacciones) y excelente calificación (3.55).
- **Clúster 0 (Cine de Prestigio):** Ej. *Schindler's List*. Calificaciones superiores (3.57) con foco en los géneros Drama y Romance, y consumo más de nicho.
- **Clúster 1 (Acción B / Comedia Genérica):** Alta popularidad pero severo castigo en calificaciones (2.98).

7. Conclusiones Metodológicas y Trabajo Futuro

1. **Límites Lineales:** Los modelos matriciales clásicos convergen rápidamente, pero la asimetría de la matriz de calificaciones requiere mayor expresividad.
2. **Siguiente Iteración (Deep Learning):** El éxito de los factores latentes (demostrado en el clustering) justifica la transición hacia la Fase 3, donde se utilizarán *Embeddings* embebidos en una arquitectura *Neural Collaborative Filtering (NCF)* con PyTorch, con la expectativa de capturar interacciones no lineales de usuario-ítem que SVD no puede resolver.